Προηγμένες Τεχνικές Επεξεργασίας Σημάτων

Work 4

Ονοματεπώνυμο: Πέτρος Χαραλαμπίδης
ΑΕΜ: 11096
Ημερομηνία: 24 Σεπτεμβρίου 2026

Aristotle University of Thessaloniki

Περιεχόμενα

1 Σκοπός της εργασίας **2**

2 Συνθήκες ηχογράφησης **2**

3 Θεωρητικό υπόβαθρο **2**
3.1 Μοντέλο πηγής-φίλτρου . . . 2
3.2 Real και complex cepstrum . . . 3
3.3 Cepstral εκτίμηση της θεμελιώδους συχνότητας . . . 3
3.4 Liftering και deconvolution . . . 3
3.5 Σύγκριση ανδρικής και γυναικείας φωνής . . . 4
3.6 HOSA και bispectrum . . . 4

4 Μεθοδολογία και υλοποίηση **4**

5 Αποτελέσματα **5**
5.1 Συνοπτική σύγκριση . . . 5
5.2 Αναλυτικά διαγράμματα . . . 6

6 Ευρήματα **12**
6.1 Cepstral χαρακτηριστικά . . . 12
6.2 Επίδραση του lifter . . . 12
6.3 Ποιότητα επανασύνθεσης . . . 12
6.4 Περιορισμοί . . . 13

7 Συμπεράσματα **13**

Α΄ Πλήρης κώδικας MATLAB **14**

1 Σκοπός της εργασίας

Σκοπός της εργασίας είναι η μελέτη ηχογραφημένων σημάτων φωνής στο *cepstral domain*, ο διαχωρισμός της διέγερσης από τη φωνητική οδό μέσω ομομορφικού φιλτραρίσματος και η επανασύνθεση των σημάτων. Χρησιμοποιήθηκαν δέκα ηχογραφήσεις: μία ανδρική και μία γυναικεία για καθένα από τα γράμματα A, E, I, O και U.

Στις παρούσες ηχογραφήσεις εξετάζονται τα αγγλικά ονόματα των γραμμάτων. Έτσι, οι εκφορές A, I και O περιλαμβάνουν χρονικά μεταβαλλόμενους διφθόγγους /eɪ/, /aɪ/ και /oʊ/, αντίστοιχα. Η ιδιότητα αυτή λαμβάνεται υπόψη στην ακουστική επανασύνθεση μέσω χρονικά μεταβαλλόμενου μοντέλου LPC.

2 Συνθήκες ηχογράφησης

Συνθήκες καταγραφής. Οι ηχογραφήσεις πραγματοποιήθηκαν με iPhone 13 και ενσύρματα ακουστικά Apple, χρησιμοποιώντας το μικρόφωνο των ακουστικών. Τα αρχεία αποθηκεύτηκαν σε μορφή M4A.

Κάθε στερεοφωνικό αρχείο μετατράπηκε σε μονοφωνικό με μέσο όρο των καναλιών. Στη συνέχεια αφαιρέθηκε η συνεχής συνιστώσα και το σήμα κανονικοποιήθηκε ως προς τη μέγιστη απόλυτη τιμή του. Με αυτόν τον τρόπο οι συγκρίσεις δεν επηρεάζονται από διαφορετική στάθμη εγγραφής.

3 Θεωρητικό υπόβαθρο

3.1 Μοντέλο πηγής-φίλτρου

Σύμφωνα με το μοντέλο ομιλίας των διαλέξεων, ένα έμφωνο σήμα προκύπτει από τη συνέλιξη μιας σχεδόν περιοδικής ακολουθίας γλωττιδικών παλμών με την κρουστική απόκριση της φωνητικής οδού:

$$x[n] = e[n] * h[n], \tag{1}$$

όπου $e[n]$ είναι η διέγερση των φωνητικών χορδών, $h[n]$ η κρουστική απόκριση της φωνητικής οδού και $*$ δηλώνει συνέλιξη. Οι δύο συνιστώσες καταλαμβάνουν κοινές περιοχές συχνοτήτων, οπότε δεν μπορούν γενικά να διαχωριστούν με ένα συνηθισμένο LTI φίλτρο. Η γραμμική πρόβλεψη αντιμετωπίζει το πρόβλημα παραμετρικά, εκτιμώντας πρώτα το σύστημα και ανακτώντας έπειτα την πηγή με αντίστροφο φιλτράρισμα. Η ομομορφική επεξεργασία αποτελεί μη παραμετρική, μετασχηματιστική προσέγγιση στο ίδιο πρόβλημα deconvolution.

Στο πεδίο της συχνότητας ισχύει

$$X[k] = E[k]H[k]. \tag{2}$$

Η βασική ιδέα της γενικευμένης επαλληλίας είναι ότι ένας αντιστρέψιμος, μη γραμμικός χαρακτηριστικός τελεστής μετατρέπει τη συνέλιξη σε πρόσθεση. Στην πράξη χρησιμοποιείται η ακολουθία Fourier transform, complex logarithm και inverse Fourier transform. Επομένως,

$$\log X[k] = \log E[k] + \log H[k], \tag{3}$$

και το αρχικό μη γραμμικό πρόβλημα διαχωρισμού γίνεται γραμμικό πρόβλημα φιλτραρίσματος στο cepstral domain. Μετά το liftering εφαρμόζεται ο αντίστροφος χαρακτηριστικός τελεστής, ώστε οι επιμέρους συνιστώσες να επιστρέψουν στο πεδίο του χρόνου.

3.2 Real και complex cepstrum

Ο μιγαδικός λογάριθμος γράφεται ως

$$\log X[k] = \log |X[k]| + j\phi_u[k], \tag{4}$$

όπου $\phi_u[k]$ είναι η συνεχής, unwrapped φάση. Η διαδικασία unwrapping είναι απαραίτητη, επειδή η κύρια τιμή της φάσης έχει ασάφεια κατά ακέραια πολλαπλάσια του 2π. Το complex cepstrum ορίζεται ως

$$c_c[n] = \text{IDFT}\{\log |X[k]| + j\phi_u[k]\}\,. \tag{5}$$

Επειδή διατηρεί μέτρο και φάση, επιτρέπει αντιστροφή και ομομορφική ανάλυση-σύνθεση. Θετικές και αρνητικές quefrencies συνδέονται με minimum-phase και maximum-phase συνιστώσες, αντίστοιχα. Στην παρούσα εργασία χρησιμοποιήθηκε η αιτιατή, minimum-phase εκτίμηση της φωνητικής οδού.

Το real cepstrum ορίζεται από το λογαριθμικό μέτρο:

$$c_r[n] = \text{IDFT}\{\log |X[k]|\}\,. \tag{6}$$

Για πραγματικό σήμα είναι πραγματικό και άρτιο, αλλά δεν διατηρεί τη φάση και άρα δεν προσδιορίζει μοναδικά την αρχική κυματομορφή. Είναι όμως ιδιαίτερα χρήσιμο για φασματική εξομάλυνση και εκτίμηση του pitch. Η ανεξάρτητη μεταβλητή του cepstrum ονομάζεται *quefrency* και έχει μονάδες χρόνου.

3.3 Cepstral εκτίμηση της θεμελιώδους συχνότητας

Η σχεδόν περιοδική γλωττιδική διέγερση δημιουργεί αρμονική λεπτομέρεια στο φάσμα. Μετά τον λογάριθμο και την IDFT, η περιοδικότητα αυτή εμφανίζεται ως ισχυρή κορυφή στην περίοδο T_0 και ως ασθενέστερες κορυφές στα ακέραια πολλαπλάσιά της. Στην ορολογία του cepstrum οι κορυφές αυτές ονομάζονται *rahmonics*. Έτσι:

$$F_0 = \frac{1}{T_0}. \tag{7}$$

Η αναζήτηση της κορυφής περιορίζεται σε φυσιολογικό εύρος F_0, ώστε να μην επιλεγεί λανθασμένα κάποια χαμηλή quefrency της φασματικής περιβάλλουσας ή κάποιο υψηλότερο rahmonic.

3.4 Liftering και deconvolution

Στο cepstral domain η συνέλιξη πηγής-φίλτρου προσεγγίζεται από το άθροισμα

$$c_x[n] = c_e[n] + c_h[n]. \tag{8}$$

Η φωνητική οδός μεταβάλλει ομαλά τη φασματική περιβάλλουσα και συγκεντρώνεται κυρίως κοντά στην αρχή του άξονα quefrency. Αντίθετα, η περιοδική διέγερση εμφανίζεται

γύρω από T_0 και τα rahmonics της. Ένα low-quefrency lifter διατηρεί επομένως κυρίως το $c_h[n]$, ενώ το συμπληρωματικό high-quefrency lifter διατηρεί κυρίως το $c_e[n]$.

Για κάθε δείγμα χρησιμοποιήθηκε συμμετρικό low-quefrency lifter με ημιπλάτος

$$T_L = \text{clip}(0.45T_0,\ 1.5\ \text{ms},\ 3.5\ \text{ms}). \tag{9}$$

Η σύνδεση του T_L με το T_0 ακολουθεί τη θεωρητική απαίτηση το low-pass lifter να τελειώνει πριν από την πρώτη κορυφή του pitch. Υπερβολικά μικρό lifter προκαλεί έντονη φασματική εξομάλυνση, διεύρυνση ή συγχώνευση των formants και πιο ``muffled'' σύνθεση. Υπερβολικά μεγάλο lifter αφήνει μέρος της αρμονικής δομής της πηγής μέσα στην εκτίμηση της φωνητικής οδού. Το low-pass τμήμα αντιστρέφεται για να δώσει το $h[n]$, ενώ το high-pass τμήμα δίνει τη deconvolved διέγερση.

Η θεωρία επισημαίνει επίσης ότι ο χρονικός παραθυρισμός διαταράσσει το ακριβές μοντέλο συνέλιξης. Για τον περιορισμό αυτού του σφάλματος επιλέχθηκε ισχυρό voiced frame περίπου τριών περιόδων και εφαρμόστηκε παράθυρο Hamming, όπως προτείνεται για short-time cepstral analysis.

3.5 Σύγκριση ανδρικής και γυναικείας φωνής

Η γυναικεία φωνή αναμένεται γενικά να έχει μεγαλύτερη F_0 και μικρότερη περίοδο T_0. Επομένως, τα rahmonics απέχουν λιγότερο μεταξύ τους και μέσα σε ένα σταθερό εύρος quefrency μπορούν να εμφανιστούν περισσότερες κορυφές. Αυτή είναι και η αναμενόμενη τάση που αναφέρεται ρητά στην εκφώνηση των διαλέξεων. Δεν αποτελεί όμως απόλυτο κριτήριο φύλου: η μέτρηση επηρεάζεται από την ένταση, τον θόρυβο, την άρθρωση, το μήκος και τη θέση του frame, καθώς και από το κατώφλι ανίχνευσης κορυφών.

3.6 HOSA και bispectrum

Το bispectrum είναι η διδιάστατη Fourier transform της cumulant τρίτης τάξης. Επειδή οι cumulants τάξης μεγαλύτερης του δύο μηδενίζονται για Gaussian διεργασίες, οι HOS είναι ευαίσθητες στη μη Gaussian και μη γραμμικά συζευγμένη δομή, ενώ το bispectrum είναι επίσης αναλλοίωτο σε κοινή γραμμική χρονική μετατόπιση . Το μέγιστο $|B(f_1, f_2)|$ χρησιμοποιείται εδώ μόνο ως συμπληρωματικός δείκτης τρίτης τάξης. Δεν αντικαθιστά το cepstrum, δεν συμμετέχει στη σύνθεση και, χωρίς κανονικοποίηση σε bicoherence, δεν αποτελεί από μόνο του μέτρο ποιότητας.

4 Μεθοδολογία και υλοποίηση

Η επεξεργασία πραγματοποιήθηκε στο MATLAB με τα ακόλουθα βήματα:

1. Ανάγνωση του αρχείου, μετατροπή σε mono, αφαίρεση DC και κανονικοποίηση.
2. Εντοπισμός περιοχής μεγάλης ενέργειας με κινούμενο RMS.
3. Αρχική εκτίμηση F_0 από το real cepstrum σε εύρος 70-220 Hz για την ανδρική και 130-350 Hz για τη γυναικεία φωνή.
4. Επιλογή adaptive frame περίπου τριών περιόδων, με όρια 12-50 ms, και εφαρμογή παραθύρου Hamming.

5. Υπολογισμός real και complex cepstrum με zero padding.

6. Low/high-quefrency liftering και αντίστροφο complex cepstrum για εκτίμηση της φωνητικής οδού και της deconvolved διέγερσης.

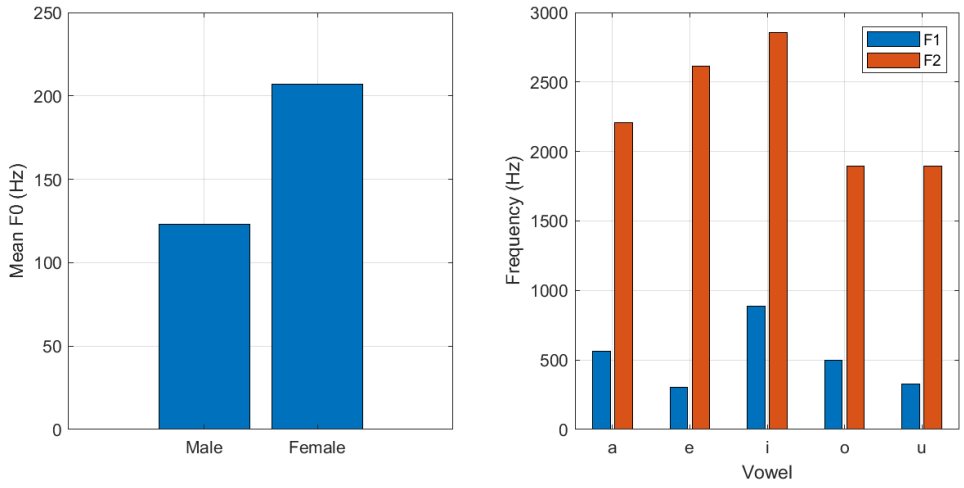
7. Εκτίμηση των formants με μοντέλο LPC από σταθερό τμήμα 150 ms.

8. Παραγωγή δύο αρχείων: `synth_*.wav` με χρονικά μεταβαλλόμενο LPC και `synth_cepstral_*.wav` με το cepstral φίλτρο του επιλεγμένου frame.

Για τη χρονικά μεταβαλλόμενη σύνθεση χρησιμοποιήθηκαν LPC frames διάρκειας 60 ms με επικάλυψη 50%. Με αυτόν τον τρόπο η φασματική περιβάλλουσα ακολουθεί τις μεταβάσεις /eɪ/, /aɪ/ και /oʊ/ αντί να επαναλαμβάνεται ένα μόνο σταθερό φωνήεν. Η διέγερση παράγεται από ομαλό glottal model με μικρό jitter, shimmer και πολύ χαμηλή συνιστώσα aspiration noise.

5 Αποτελέσματα

5.1 Συνοπτική σύγκριση



Σχήμα 1: Σύγκριση μέσης θεμελιώδους συχνότητας ανά φύλο και προσεγγιστικών formants F_1, F_2 ανά γράμμα.

Πίνακας 1: Ποσοτικά αποτελέσματα για τα δέκα δείγματα.

#	Voice	Letter	F_0 (Hz)	Frame (ms)	Lifter (ms)	Peaks	F_1 (Hz)	F_2 (Hz)
1	Male	a	189	27.1	2.38	2	545	1,898
2	Male	e	119.7	25.1	3.5	4	270	2,367
3	Male	i	99.6	29.9	3.5	1	797	2,619
4	Male	o	103.2	29	3.5	3	434	2,643
5	Male	u	104.1	28.8	3.5	2	258	1,893
6	Female	a	196.7	15.1	2.29	2	580	2,514
7	Female	e	207.8	14.3	2.17	3	340	2,859
8	Female	i	206	14.6	2.18	2	973	3,088
9	Female	o	200.8	15.2	2.24	3	563	1,143
10	Female	u	223.3	13.3	2.02	3	398	NaN

Πίνακας 2: Συμπληρωματικοί δείκτες σύνθεσης και HOSA.

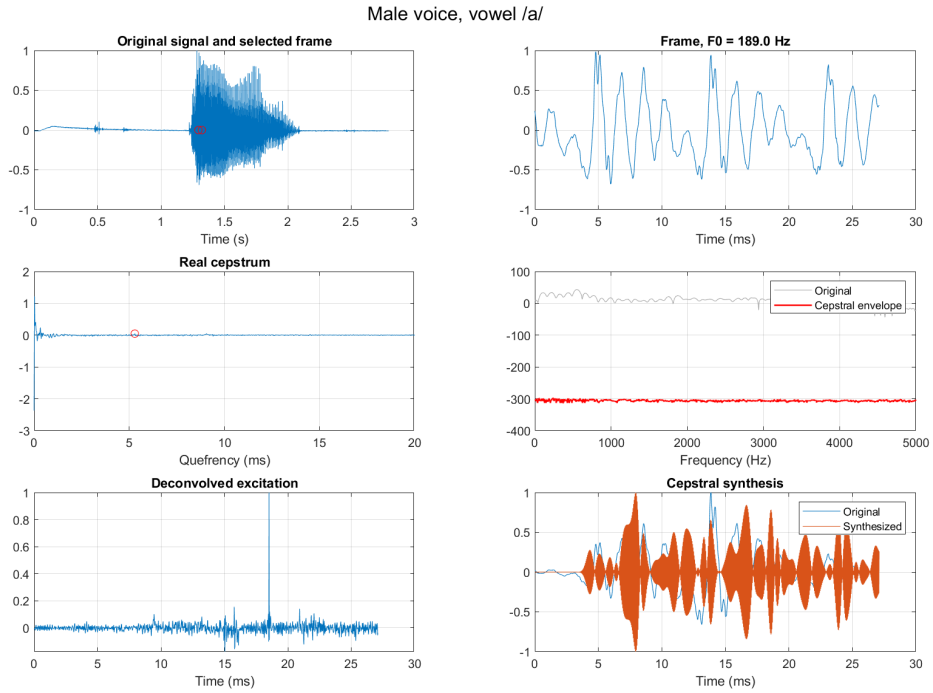
#	Voice	Letter	Spectral flatness	HOSA peak
1	Male	a	0.0001	$5.97 \cdot 10^{-4}$
2	Male	e	0.0002	$3.56 \cdot 10^{-4}$
3	Male	i	0	$7.96 \cdot 10^{-4}$
4	Male	o	0.0013	$4.36 \cdot 10^{-4}$
5	Male	u	0.0004	$2.23 \cdot 10^{-4}$
6	Female	a	0.0012	$6.01 \cdot 10^{-4}$
7	Female	e	0.0001	$2.39 \cdot 10^{-4}$
8	Female	i	0.0025	$1.77 \cdot 10^{-3}$
9	Female	o	0.0001	$3.06 \cdot 10^{-3}$
10	Female	u	0.0798	$9.63 \cdot 10^{-4}$

Η θεωρία προβλέπει ότι η θέση της κύριας cepstral κορυφής εξαρτάται κυρίως από την περίοδο της γλωττιδικής διέγερσης, ενώ η χαμηλή quefrency περιγράφει κυρίως τη φασματική περιβάλλουσα της φωνητικής οδού. Επομένως, η F_0 αναμένεται να διαφοροποιείται περισσότερο μεταξύ των δύο ομιλητών, ενώ οι θέσεις και οι χρονικές μεταβολές των formants αναμένεται να διαχωρίζουν κυρίως τα γράμματα. Το Σχήμα 1 και ο Πίνακας 1 χρησιμοποιούνται για να ελεγχθούν οι δύο αυτές προβλέψεις, καθώς και η αναμενόμενη τάση της γυναικείας φωνής για περισσότερες cepstral κορυφές μέσα στο ίδιο εύρος quefrency.

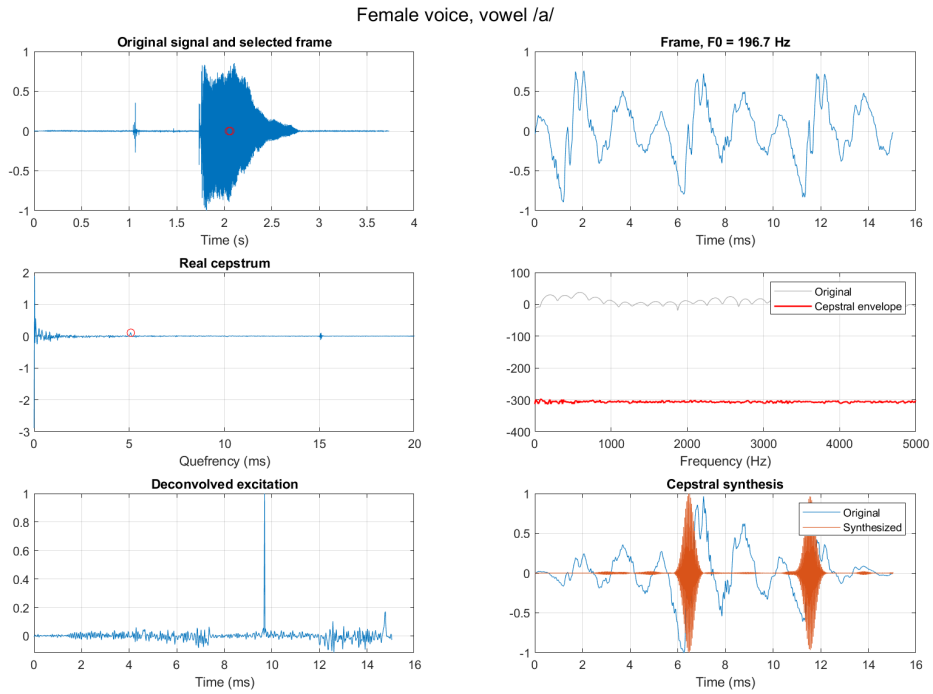
5.2 Αναλυτικά διαγράμματα

Κάθε διάγραμμα περιλαμβάνει το πλήρες αρχικό σήμα, το επιλεγμένο frame, το real cepstrum, τη φασματική περιβάλλουσα, τη deconvolved διέγερση και σύγκριση του αρχικού frame με την cepstral σύνθεση.

Ανδρική φωνή - Α

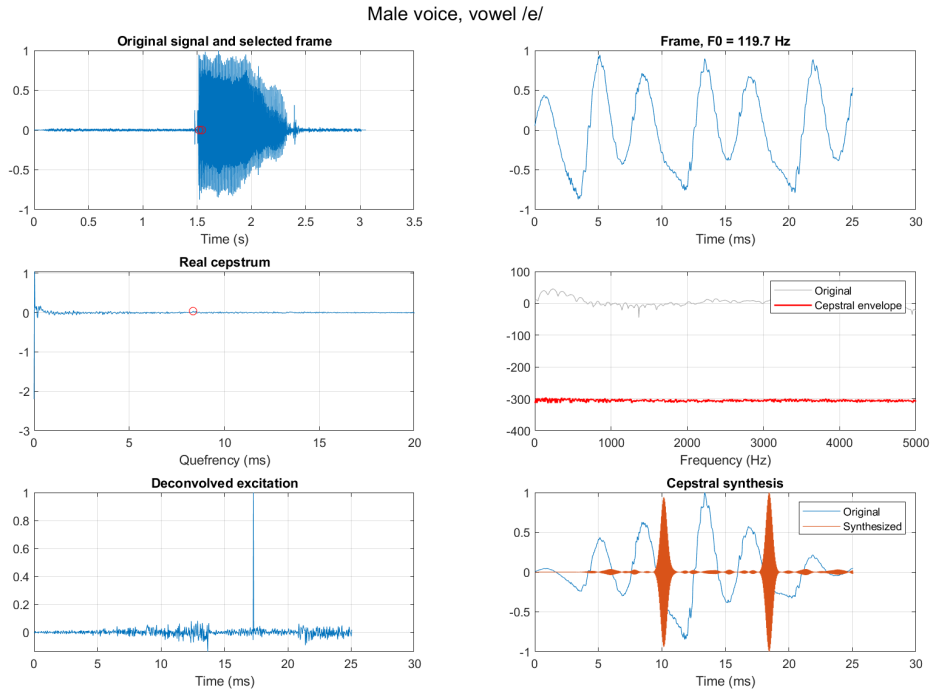


Γυναικεία φωνή - Α

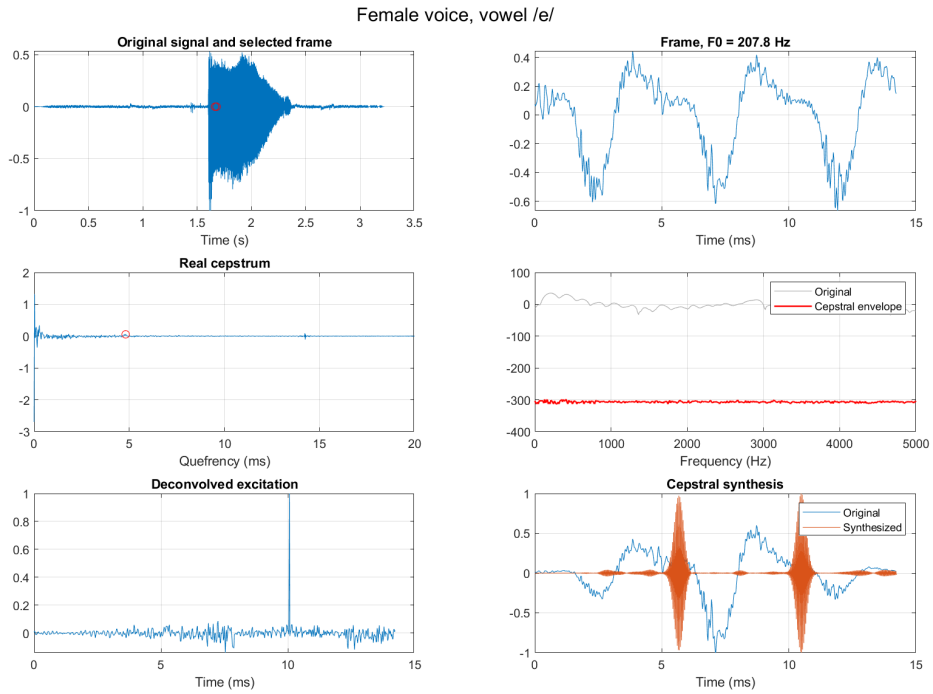


Σχήμα 2: Αναλυτικά διαγράμματα για το γράμμα Α.

Ανδρική φωνή - Ε

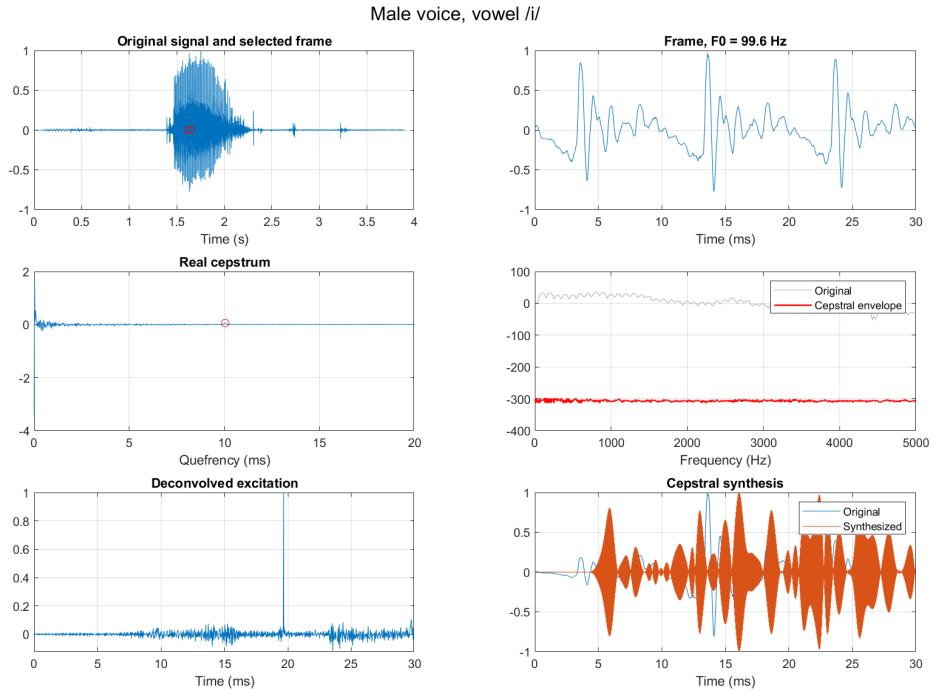


Γυναικεία φωνή - Ε

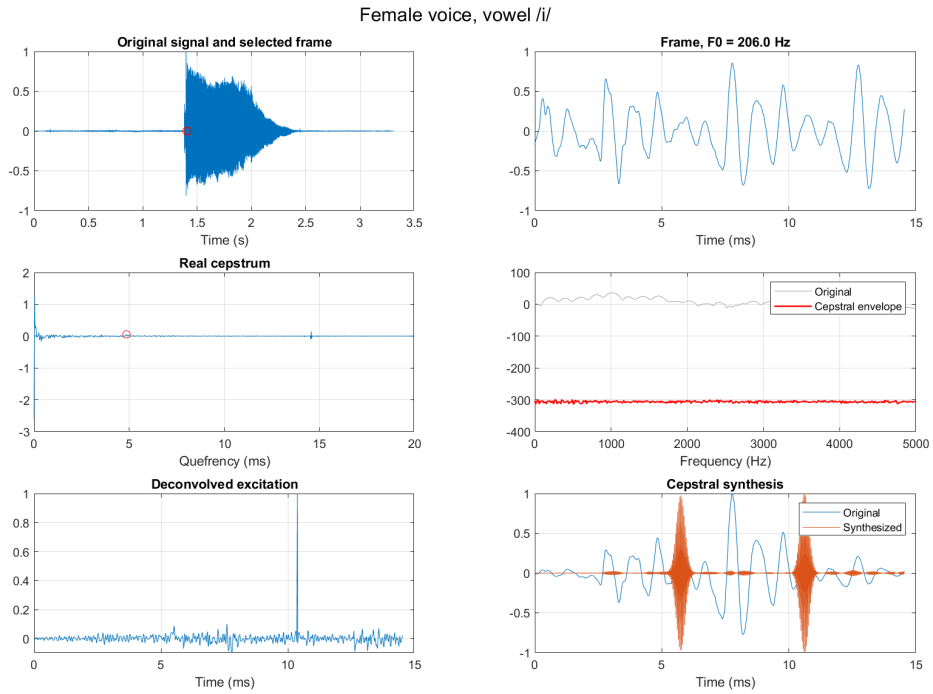


Σχήμα 3: Αναλυτικά διαγράμματα για το γράμμα Ε.

Ανδρική φωνή - I

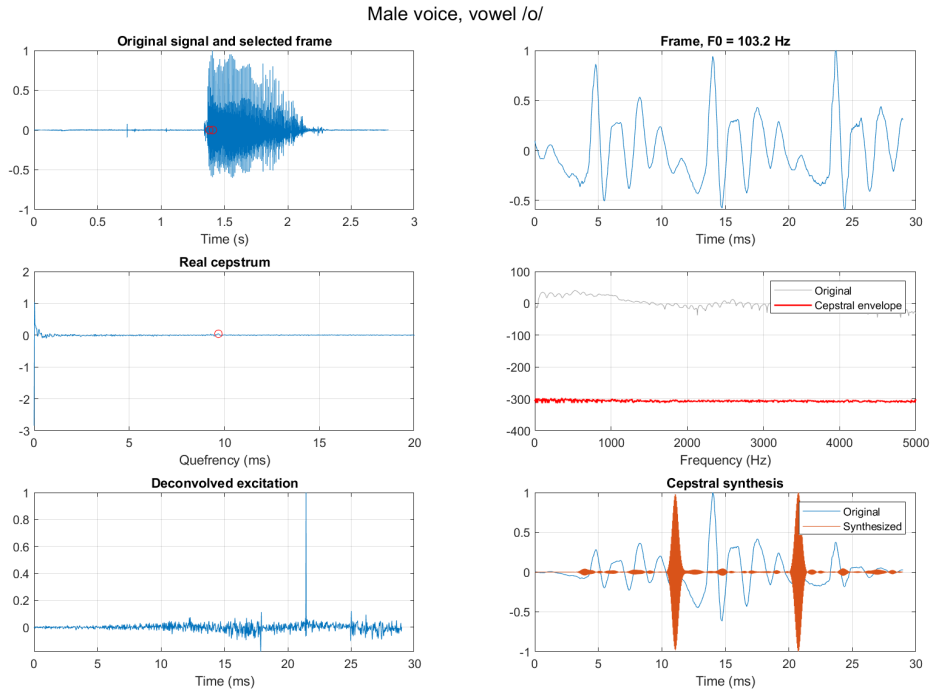


Γυναικεία φωνή - I

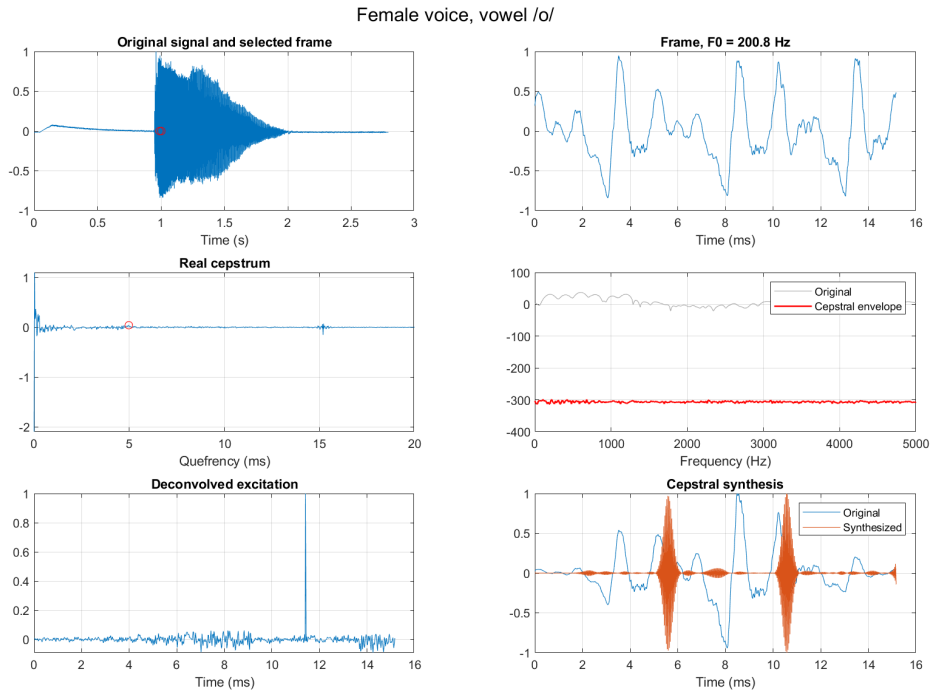


Σχήμα 4: Αναλυτικά διαγράμματα για το γράμμα I.

Ανδρική φωνή - Ο

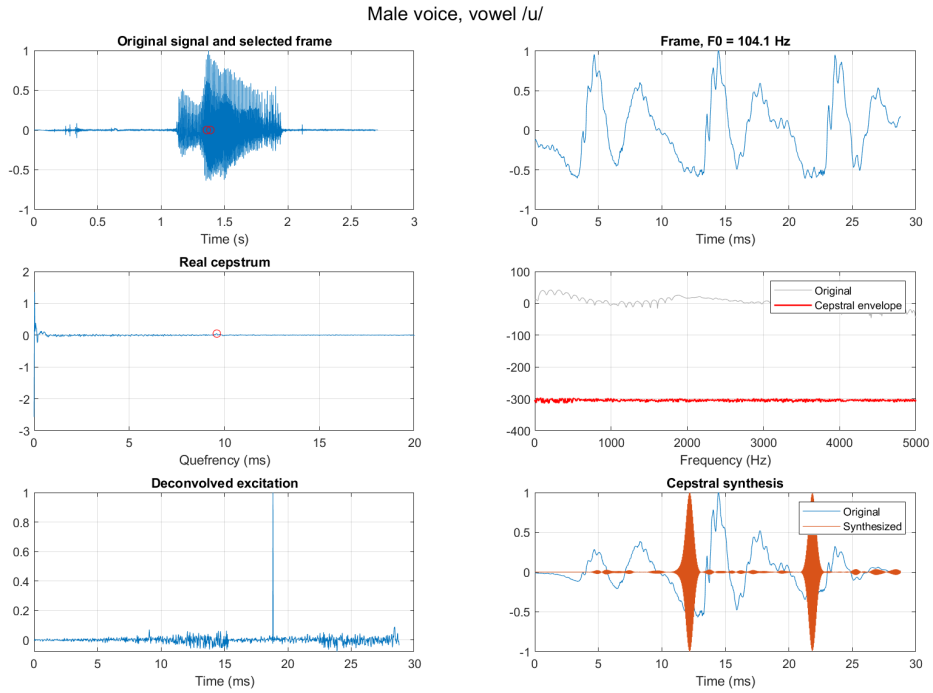


Γυναικεία φωνή - Ο

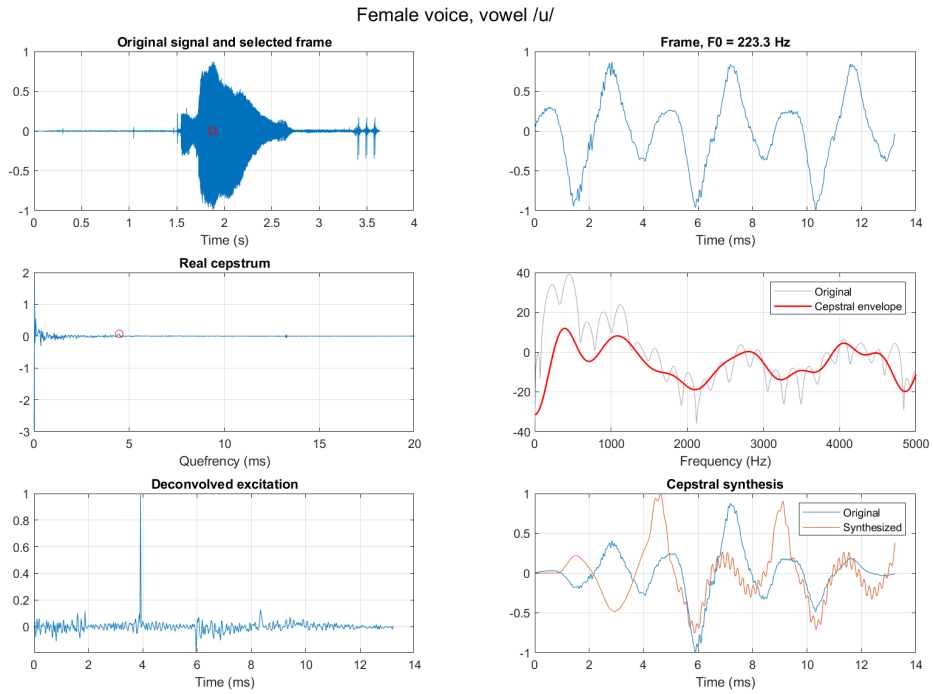


Σχήμα 5: Αναλυτικά διαγράμματα για το γράμμα Ο.

Ανδρική φωνή - U



Γυναικεία φωνή - U



Σχήμα 6: Αναλυτικά διαγράμματα για το γράμμα U.

6 Ευρήματα

6.1 Cepstral χαρακτηριστικά

Η κύρια μη μηδενική κορυφή του real cepstrum ερμηνεύεται ως η θεμελιώδης quefrency T_0. Οι επόμενες κορυφές κοντά στα $2T_0, 3T_0, \ldots$ είναι τα rahmonics της σχεδόν περιοδικής γλωττιδικής διέγερσης. Συνεπώς, μεγαλύτερη F_0 μετακινεί την πρώτη κορυφή προς μικρότερη quefrency και μειώνει την απόσταση μεταξύ διαδοχικών rahmonics. Αυτό δίνει φυσική ερμηνεία στη γενική τάση για περισσότερες κορυφές στα γυναικεία δείγματα μέσα στο ίδιο παράθυρο 20 ms.

Η τάση αυτή δεν απαιτεί να ισχύει για κάθε ζεύγος ηχογραφήσεων. Η θέση του frame, η σταθερότητα του pitch, η παρουσία θορύβου και το κατώφλι του `findpeaks` αλλάζουν τον αριθμό των μετρούμενων κορυφών. Γι' αυτό η F_0 από την ισχυρότερη κορυφή είναι πιο άμεσο cepstral μέγεθος από το πλήθος όλων των τοπικών μεγίστων. Επίσης, η χρήση frame περίπου τριών περιόδων εξασφαλίζει αρκετή περιοδική πληροφορία χωρίς να παραβιάζεται υπερβολικά η υπόθεση τοπικής στασιμότητας.

Οι διαφορές ανά γράμμα γίνονται περισσότερο εμφανείς στη φασματική περιβάλλουσα και στις θέσεις των formants, δηλαδή στη συνιστώσα χαμηλής quefrency που αποδίδεται στη φωνητική οδό. Τα A, I και O, όταν προφέρονται ως αγγλικά ονόματα γραμμάτων, είναι χρονικά μεταβαλλόμενοι δίφθογγοι. Επομένως, μία μόνο τριάδα F_1, F_2, F_3 από το κεντρικό τμήμα αποτελεί συνοπτική περιγραφή και δεν αποτυπώνει ολόκληρη τη διαδρομή των formants.

6.2 Επίδραση του lifter

Με βάση την ομομορφική αρχιτεκτονική, το lifter εφαρμόζεται αφού η συνέλιξη πηγής-φίλτρου έχει μετατραπεί σε πρόσθεση. Το low-quefrency τμήμα λειαίνει το λογαριθμικό φάσμα και διατηρεί τις ευρείες συντονιστικές περιοχές της φωνητικής οδού. Το συμπληρωματικό high-quefrency τμήμα αφαιρεί μεγάλο μέρος αυτών των συντονισμών και γι' αυτό η deconvolved έξοδος εμφανίζεται πιο παλμική και περιοδική από την αρχική κυματομορφή. Η μορφή αυτή συμφωνεί με το μοντέλο της πηγής ως ακολουθίας γλωττιδικών παλμών.

Μικρότερο lifter δίνει ισχυρότερη εξομάλυνση αλλά μπορεί να συγχωνεύσει κοντινά formants. Μεγαλύτερο lifter διατηρεί περισσότερες λεπτομέρειες, αλλά υπάρχει κίνδυνος να περάσει μέρος της περιοδικότητας της πηγής στο εκτιμώμενο φίλτρο. Η προσαρμογή στο $0.45T_0$ αποτελεί συμβιβασμό μεταξύ των δύο περιπτώσεων και κρατά το όριο πριν από την πρώτη κορυφή του pitch. Τα σταθερά όρια 1.5-3.5 ms αποτρέπουν ακραίες επιλογές όταν η αρχική εκτίμηση F_0 έχει σφάλμα.

Ο διαχωρισμός παραμένει προσεγγιστικός. Όπως επισημαίνεται στις διαλέξεις, ο χρονικός παραθυρισμός ενός σήματος που προκύπτει από συνέλιξη δεν οδηγεί ακριβώς στη συνέλιξη των αντίστοιχων παραθυρισμένων συνιστωσών. Το παράθυρο Hamming και η επιλογή περίπου τριών περιόδων μειώνουν τις ασυνέχειες και τη διαρροή, αλλά δεν εξαλείφουν αυτή την απόκλιση.

6.3 Ποιότητα επανασύνθεσης

Η έκδοση `synth_cepstral_*.wav` ακολουθεί άμεσα το απλοποιημένο source-filter μοντέλο ενός frame. Από το φιλτραρισμένο complex cepstrum κατασκευάζεται minimum-phase απόκριση φωνητικής οδού και διεγείρεται με συνθετική γλωττιδική πηγή. Η minimum-phase επιλογή δίνει αιτιατή και πρακτική ανακατασκευή, αλλά δεν αναπαράγει αναγκαστικά τη μικτή φάση του πραγματικού συστήματος. Σε συνδυασμό με τη σταθερή περιβάλ-

λουσα ενός frame, αυτό εξηγεί γιατί η έξοδος μπορεί να ακούγεται βουητή, μηχανική ή ``muffled'', όπως περιγράφεται και στη σύγκριση των μεθόδων των διαλέξεων.

Η κύρια έκδοση `synth_*.wav` χρησιμοποιεί LPC φίλτρο που μεταβάλλεται ανά 60 ms. Η μέθοδος αυτή διατηρεί καλύτερα την εξέλιξη των formants και συνεπώς τις προφορές «έι», «άι» και «όου». Παρ' όλα αυτά, η διέγερση παραμένει μοντελοποιημένη και η εκτίμηση pitch είναι συνοπτική, οπότε το αποτέλεσμα δεν αναμένεται να είναι ταυτόσημο με τη φυσική φωνή. Θεωρητικά, η LPC είναι παραμετρική all-pole deconvolution: αποδίδει καθαρές κορυφές συντονισμού, αλλά δεν αναπαριστά άμεσα τα μηδενικά και μπορεί να δώσει πιο ``crisp'' αλλά μηχανικό ήχο. Η ομομορφική μέθοδος είναι μη παραμετρική και μπορεί να αναπαραστήσει πόλους και μηδενικά, όμως η φασματική εξομάλυνση μπορεί να διευρύνει τους συντονισμούς.

Το spectral flatness χρησιμοποιήθηκε ως απλός έλεγχος ποιότητας. Τιμή κοντά στο μηδέν είναι συμβατή με περιοδικό, έμφωνο σήμα, ενώ τιμή κοντά στη μονάδα υποδεικνύει noise-like έξοδο. Δεν αποτελεί από μόνο του αντιληπτικό μέτρο ποιότητας ή αναγνωρισιμότητας.

6.4 Περιορισμοί

- Οι συμπιέσεις M4A/AAC, ο θόρυβος χώρου και η απόσταση μικροφώνου μπορούν να επηρεάσουν τις cepstral κορυφές και τα formants.
- Το real cepstrum αγνοεί τη φάση. Η ανακατασκευή βασίζεται επομένως στο complex cepstrum και στην επιλεγμένη minimum-phase προσέγγιση, όχι μόνο στο real cepstrum.
- Η LPC προσέγγιση είναι all-pole και δεν μοντελοποιεί εξίσου καλά όλες τις μηδενικές ή αντισυντονισμούς της φωνητικής οδού.
- Η σύγκριση βασίζεται σε έναν άνδρα και μία γυναίκα, άρα δεν μπορεί να γενικευθεί σε ολόκληρο τον πληθυσμό.
- Τα αγγλικά ονόματα γραμμάτων δεν είναι ισοδύναμα με πέντε σταθερά φωνήεντα. Η διάκριση αυτή πρέπει να λαμβάνεται υπόψη κατά την ερμηνεία.

7 Συμπεράσματα

Η εργασία επιβεβαιώνει την κεντρική ιδέα της ομομορφικής επεξεργασίας: ο complex logarithm μετατρέπει τη συνέλιξη πηγής-φωνητικής οδού σε πρόσθεση, ώστε οι δύο συνιστώσες να μπορούν να διαχωριστούν προσεγγιστικά με liftering. Το real cepstrum έδωσε την περίοδο T_0 από την κύρια κορυφή και τα rahmonics της, ενώ το complex cepstrum παρείχε την πληροφορία φάσης που απαιτείται για αντιστροφή και σύνθεση.

Η σύγκριση ανδρικής και γυναικείας φωνής ερμηνεύεται κυρίως μέσω της θεμελιώδους συχνότητας: μεγαλύτερη F_0 σημαίνει μικρότερη quefrency και πυκνότερα rahmonics, άρα συνήθως περισσότερες κορυφές στο ίδιο cepstral εύρος. Αντίθετα, οι διαφορές μεταξύ των γραμμάτων εμφανίζονται κυρίως στη χαμηλή quefrency, δηλαδή στη φασματική περιβάλλουσα και στα formants της φωνητικής οδού. Το pitch-adaptive lifter ακολούθησε αυτή τη διάκριση και η deconvolved έξοδος απέκτησε την αναμενόμενη παλμική μορφή της διέγερσης.

Η απλή cepstral σύνθεση επιβεβαίωσε το source-filter μοντέλο, αλλά είχε περιορισμένη φυσικότητα λόγω της σταθερής περιβάλλουσας, της minimum-phase επιλογής και των σφαλμάτων παραθυρισμού/liftering. Η χρονικά μεταβαλλόμενη LPC σύνθεση λειτούργησε ως συμπληρωματική παραμετρική μέθοδος και διατήρησε καλύτερα τις μεταβάσεις των διφθόγγων

«έι», «άι» και «όου». Ο δείκτης HOSA πρόσθεσε πληροφορία τρίτης τάξης για τη μη Gaussian δομή, χωρίς να αντικαθιστά τη cepstral ανάλυση. Συνολικά, το cepstrum είναι κατάλληλο για εκτίμηση pitch και source-filter deconvolution, αλλά πιστή ακουστική ανασύνθεση απαιτεί σωστή φάση, κατάλληλο παράθυρο και χρονικά μεταβαλλόμενη μοντελοποίηση της φασματικής περιβάλλουσας.

Α΄ Πλήρης κώδικας MATLAB

Listing 1: Πλήρης κώδικας MATLAB της εργασίας.

```
clear;
close all;
clc;

%% RYTHMISEIS
audioFolder = fullfile(pwd, 'audio');
resultsFolder = fullfile(pwd, 'results');

files = { ...
    'male_a.m4a'; 'male_e.m4a'; 'male_i.m4a'; 'male_o.m4a'; 'male_u.m4a'; ...
    'female_a.m4a'; 'female_e.m4a'; 'female_i.m4a'; 'female_o.m4a'; 'female_u.m4a'};
sex = [repmat({'Male'},5,1); repmat({'Female'},5,1)];
vowel = repmat({'a';'e';'i';'o';'u'},2,1);

maleF0Range = [70 220];
femaleF0Range = [130 350];
useHOSA = true;

if ~exist(resultsFolder,'dir'), mkdir(resultsFolder); end
if ~exist(audioFolder,'dir'), error('Den vrethike o fakelos audio.'); end

for k = 1:numel(files)
    if ~exist(fullfile(audioFolder,files{k}),'file')
        error('Leipei to arxeio: %s',files{k});
    end
end

if useHOSA && exist('bispecd','file') ~= 2
    warning('Den vrethike to HOSA bispecd. I ypoloipi analysi tha ginei kanonika.');
end

%% ANALYSI
R = repmat(struct(),numel(files),1);

for k = 1:numel(files)
    [x,fs] = audioread(fullfile(audioFolder,files{k}));
    if size(x,2)>1, x = mean(x,2); end
    x = x(:)-mean(x(:));
    x = x/(max(abs(x))+eps);

    if strcmp(sex{k},'Male')
        f0Range = maleF0Range;
    else
        f0Range = femaleF0Range;
    end

    % Dynato voiced frame 3 periodon.
    [frameRaw,frameStart] = voicedFrame(x,fs,f0Range);
    N = numel(frameRaw);
    frame = frameRaw.*hamming(N);
    nfft = 2^nextpow2(max(2048,4*N));
    framePadded = [frame; zeros(nfft-N,1)];

    % Real kai complex cepstrum.
    cReal = rceps(framePadded);
    [cComplex,phaseDelay] = cceps(framePadded);
    f0 = cepstralPitch(cReal,fs,f0Range);
    T0 = 1/f0;
```

```
59
60      % Low/high-quefrency liftering.
61      lifterSec = min(max(0.45*T0,0.0015),0.0035);
62      L = round(lifterSec*fs);
63      lowLifter = zeros(nfft,1);
64      lowLifter(1:L+1) = 1;
65      lowLifter(end-L+1:end) = 1;
66
67      % Minimum-phase vocal-tract filter kai deconvolved excitation.
68      cFilter = cComplex.*lowLifter;
69      cMinimum = zeros(nfft,1);
70      cMinimum(1:L+1) = cFilter(1:L+1);
71      h = real(icceps(cMinimum,0));
72      h = h(1:min(round(0.03*fs),numel(h)));
73      h = h/(sqrt(sum(h.^2))+eps);
74
75      excitation = real(icceps(cComplex.*(1-lowLifter),phaseDelay));
76      excitation = excitation(1:N);
77      excitation = excitation/(max(abs(excitation))+eps);
78
79      % To cepstrum thelei short frame, alla oi formants theloun perissotera
80      % dedomena. Gia to akoustiko LPC xrisimopoioume stathero tmima 150 ms.
81      frameCenter = frameStart+floor((N-1)/2);
82      lpcN = min(round(0.150*fs),numel(x));
83      lpcFrame = takeFrame(x,frameCenter,lpcN).*hamming(lpcN);
84      lpcOrder = min([40, max(12,round(fs/1000)+2), lpcN-2]);
85      [a,lpcError] = lpc(lpcFrame,lpcOrder);
86      a = real(a).*(0.996.^(0:lpcOrder));
87
88      [Hlpc,fLpc] = freqz(1,a,4096,fs);
89      formants = findFormants(fLpc,20*log10(abs(Hlpc)+eps));
90
91      % Akoustiki synthesi me time-varying LPC: diatirei tis metavaseis
92      % /eI/, /aI/, /oU/ ton agglikon onomaton A, I kai O.
93      outputN = min(numel(x),round(5*fs));
94      source = glottalSource(f0,fs,outputN,k);
95      synth = finishAudio(timeVaryingLpc(x(1:outputN),source,fs,lpcOrder),fs);
96      synthCepstral = finishAudio(filter(h,1,source),fs);
97
98      [~,name] = fileparts(files{k});
99      audiowrite(fullfile(resultsFolder,['synth_' name '.wav']),synth,fs);
100     audiowrite(fullfile(resultsFolder,['synth_cepstral_' name '.wav']), ...
101         synthCepstral,fs);
102
103     % Aples posotikes metriseis.
104     qMax = min(round(0.020*fs)+1,floor(nfft/2));
105     region = cReal(2:qMax);
106     [peaks,~] = findpeaks(region);
107     peakLimit = median(region)+0.10*(max(region)-min(region));
108     cepstralPeakCount = sum(peaks>peakLimit);
109     flatness = spectralFlatness(synth,fs);
110
111     hosaPeak = NaN;
112     if useHOSA && exist('bispecd','file')==2
113         try
114             B = bispecd(frameRaw,64,1,min(64,N),0);
115             hosaPeak = max(abs(B(:)));
116         catch ME
117             warning('HOSA error sto %s: %s',files{k},ME.message);
118         end
119     end
120
121     % Ena sxhma ana ixografisi.
122     f = (0:nfft/2)'*fs/nfft;
123     X = fft(framePadded);
124     H = fft(h,nfft);
125     q = (0:qMax-1)'/fs;
126     sourceFrame = source(1:N);
127     modelFrame = filter(h,1,sourceFrame);
128
129     fig = figure('Visible','off','Color','w','Position',[50 50 1200 800]);
130     subplot(3,2,1);
131     plot((0:numel(x)-1)/fs,x); hold on;
```

```
    plot(([frameStart frameStart+N-1]-1)/fs,[0 0],'or');
    grid on; xlabel('Time (s)'); title('Original signal and selected frame');

    subplot(3,2,2);
    plot((0:N-1)*1000/fs,frameRaw);
    grid on; xlabel('Time (ms)');
    title(sprintf('Frame, F0 = %.1f Hz',f0));

    subplot(3,2,3);
    plot(q*1000,cReal(1:qMax)); hold on;
    plot(1000/f0,interp1(q*1000,cReal(1:qMax),1000/f0),'or');
    grid on; xlabel('Quefrency (ms)'); title('Real cepstrum');

    subplot(3,2,4);
    plot(f,20*log10(abs(X(1:numel(f)))+eps),'Color',[.65 .65 .65]); hold on;
    plot(f,20*log10(abs(H(1:numel(f)))+eps),'r','LineWidth',1.2);
    xlim([0 min(5000,fs/2)]); grid on;
    xlabel('Frequency (Hz)'); legend('Original','Cepstral envelope');

    subplot(3,2,5);
    plot((0:N-1)*1000/fs,excitation);
    grid on; xlabel('Time (ms)'); title('Deconvolved excitation');

    subplot(3,2,6);
    plot((0:N-1)*1000/fs,frame/(max(abs(frame))+eps)); hold on;
    plot((0:N-1)*1000/fs,modelFrame/(max(abs(modelFrame))+eps));
    grid on; xlabel('Time (ms)'); legend('Original','Synthesized');
    title('Cepstral synthesis');

    sgtitle(sprintf('%s voice, vowel /%s/',sex{k},vowel{k}));
    saveas(fig,fullfile(resultsFolder,sprintf('%02d_%s_analysis.png',k,name)));
    close(fig);

    R(k).File = files{k};
    R(k).Sex = sex{k};
    R(k).Vowel = vowel{k};
    R(k).Fs_Hz = fs;
    R(k).F0_Hz = f0;
    R(k).Frame_ms = 1000*N/fs;
    R(k).Lifter_ms = 1000*lifterSec;
    R(k).CepstralPeaks = cepstralPeakCount;
    R(k).F1_Hz = formants(1);
    R(k).F2_Hz = formants(2);
    R(k).F3_Hz = formants(3);
    R(k).LPC_Error = lpcError;
    R(k).SynthFlatness = flatness;
    R(k).HOSA_Peak = hosaPeak;

    fprintf('%2d/10  %-14s  F0=%6.1f Hz  F1=%4.0f  F2=%4.0f\n', ...
        k,files{k},f0,formants(1),formants(2));
end

%% SYGKRISEIS
T = struct2table(R);
writetable(T,fullfile(resultsFolder,'quantitative_results.csv'));

isMale = strcmp(T.Sex,'Male');
meanF0 = [mean(T.F0_Hz(isMale)),mean(T.F0_Hz(~isMale))];
vowels = {'a','e','i','o','u'};
F1 = zeros(5,1); F2 = zeros(5,1);
for k=1:5
    idx = strcmp(T.Vowel,vowels{k});
    F1(k) = mean(T.F1_Hz(idx),'omitnan');
    F2(k) = mean(T.F2_Hz(idx),'omitnan');
end

fig = figure('Visible','off','Color','w','Position',[100 100 900 400]);
subplot(1,2,1); bar(meanF0); grid on;
set(gca,'XTickLabel',{'Male','Female'}); ylabel('Mean F0 (Hz)');
subplot(1,2,2); bar([F1 F2]); grid on;
set(gca,'XTickLabel',vowels); ylabel('Frequency (Hz)');
legend('F1','F2'); xlabel('Vowel');
saveas(fig,fullfile(resultsFolder,'00_summary_comparison.png'));
```

```
close(fig);

fprintf('\nOloklirothike. Apotelesmata: %s\n',resultsFolder);

%% TOPIKES SYNARTISEIS
function [frame,startIndex] = voicedFrame(x,fs,f0Range)
    roughN = min(numel(x),round(0.050*fs));
    energy = movmean(x.^2,max(3,round(0.020*fs)));
    [~,center] = max(energy);
    rough = takeFrame(x,center,roughN);
    nfft = 2^nextpow2(max(2048,4*roughN));
    c = rceps([rough.*hamming(roughN); zeros(nfft-roughN,1)]);
    f0 = cepstralPitch(c,fs,f0Range);

    N = round(3*fs/f0);
    N = min(max(N,round(0.012*fs)),round(0.050*fs));
    N = min(N,numel(x));
    startIndex = min(max(1,center-floor(N/2)),numel(x)-N+1);
    frame = x(startIndex:startIndex+N-1);
    frame = frame-mean(frame);
end

function y = takeFrame(x,center,N)
    first = min(max(1,center-floor(N/2)),numel(x)-N+1);
    y = x(first:first+N-1);
end

function f0 = cepstralPitch(c,fs,f0Range)
    first = round(fs/f0Range(2))+1;
    last = min(round(fs/f0Range(1))+1,floor(numel(c)/2));
    region = c(first:last);
    [peaks,locations] = findpeaks(region);
    if isempty(peaks)
        [~,location] = max(region);
    else
        [~,best] = max(peaks);
        location = locations(best);
    end
    period = first+location-2;
    f0 = fs/period;
end

function formants = findFormants(f,envelopeDb)
    idx = find(f>=150 & f<=min(4000,max(f)));
    df = f(2)-f(1);
    [~,locations] = findpeaks(envelopeDb(idx), ...
        'MinPeakDistance',max(1,round(200/df)), ...
        'MinPeakProminence',2);
    values = f(idx(locations));
    formants = NaN(1,3);
    formants(1:min(3,numel(values))) = values(1:min(3,numel(values)));
end

function source = glottalSource(f0,fs,N,seed)
    P = max(2,round(fs/f0));
    t = (0:P-1)'/P;
    flow = zeros(P,1);
    opening = t<0.45;
    closing = t>=0.45 & t<0.75;
    flow(opening) = 0.5*(1-cos(pi*t(opening)/0.45));
    flow(closing) = cos(0.5*pi*(t(closing)-0.45)/0.30);
    cycle = [flow(1);diff(flow)];
    cycle = cycle/(sqrt(sum(cycle.^2))+eps);

    oldState = rng; rng(seed,'twister');
    source = zeros(N,1); position = 1;
    while position<=N
        last = min(N,position+P-1);
        source(position:last) = source(position:last)+ ...
            (1+0.02*randn)*cycle(1:last-position+1);
        position = position+round(P*(1+0.003*randn));
    end
    source = source+0.002*sqrt(mean(source.^2))*randn(N,1);
```

```
    rng(oldState);
end

function y = timeVaryingLpc(x,source,fs,order)
    % LPC ana 60 ms me 50% overlap. Etsi i spectral envelope akolouthei
    % tin arxiki profora anti na epanalamvanei ena mono stathero fonien.
    N = min(numel(x),numel(source));
    frameN = min(round(0.060*fs),N);
    hop = max(1,floor(frameN/2));
    starts = unique([1:hop:N-frameN+1, N-frameN+1]);
    window = hamming(frameN);
    referenceRms = sqrt(max(movmean(x(1:N).^2,frameN)));

    y = zeros(N,1);
    weight = zeros(N,1);
    for first = starts
        idx = first:first+frameN-1;
        originalFrame = x(idx);
        frameRms = sqrt(mean(originalFrame.^2));
        if frameRms < 0.01*referenceRms
            continue;
        end

        currentOrder = min(order,frameN-2);
        a = lpc(originalFrame.*window,currentOrder);
        a = real(a).*(0.996.^(0:currentOrder));
        frameOut = filter(1,a,source(idx));
        frameOut = frameOut*frameRms/(sqrt(mean(frameOut.^2))+eps);

        y(idx) = y(idx)+frameOut.*window;
        weight(idx) = weight(idx)+window;
    end
    y = y./(weight+eps);
end

function y = finishAudio(y,fs)
    y = y(:)-mean(y(:));
    fadeN = min(round(0.03*fs),floor(numel(y)/2));
    if fadeN>1
        fade = 0.5-0.5*cos(pi*(0:fadeN-1)'/(fadeN-1));
        y(1:fadeN) = y(1:fadeN).*fade;
        y(end-fadeN+1:end) = y(end-fadeN+1:end).*flipud(fade);
    end
    y = 0.95*y/(max(abs(y))+eps);
end

function value = spectralFlatness(x,fs)
    N = min(numel(x),round(0.5*fs));
    x = x(1:N).*hamming(N);
    P = abs(fft(x,2^nextpow2(N))).^2;
    f = (0:numel(P)-1)'*fs/numel(P);
    P = P(f>=60 & f<=min(5000,0.48*fs))+eps;
    value = exp(mean(log(P)))/mean(P);
end
```